



UNIVERSIDADE FEDERAL DE SANTA MARIA

DEPARTAMENTO DE ESTATÍSTICA

Introdução

Professor: Luan Portella

Disciplina: Séries temporais

Cachoeira do Sul - RS, 13 de agosto de 2026

O tempo: permanência, ciclos e mudanças

“We live embedded in the passage of time—a matrix marked by all possible standards of judgment: by immanent things that do not appear to change; by cosmic recurrences of days and seasons; by unique events of battles and natural disasters; by an apparent directionality of life from birth and growth to decrepitude, death, and decay.”

Stephen Jay Gould
Time's Arrow, Time's Cycle

Sobre modelos

“Essencialmente, todos os modelos estão errados, mas alguns são úteis.”

George E. P. Box
Empirical Model-Building and Response Surfaces
Box e Draper (1987)

Séries temporais: uma breve história

- **Medicina:** acompanhamento de epidemias, mortalidade, sinais vitais e efeitos de intervenções.
- **Astronomia:** observação de ciclos celestes, eclipses, fases da Lua e movimentos planetários.
- **Meteorologia:** registro de temperatura, chuvas, pressão atmosférica e padrões sazonais.
- **Economia:** análise de preços, inflação, produção, desemprego, juros e ciclos econômicos.

Em diferentes áreas, observar o tempo sempre foi uma forma de reconhecer padrões, antecipar mudanças e tomar decisões.

John Graunt e os registros de mortalidade

- **John Graunt** era um comerciante londrino de itens de vestuário.
- Analisou os registros semanais de mortes publicados em Londres.
- Em 1662, publicou *Natural and Political Observations Made upon the Bills of Mortality*.
- Seu trabalho é considerado um marco inicial da demografia, da estatística vital e da análise quantitativa de dados populacionais.

Febre puerperal: uma intervenção no tempo

- No Hospital Geral de Viena, Semmelweis observou alta mortalidade materna por febre puerperal.
- Em 1847, introduziu a lavagem das mãos com solução de cal clorada antes dos atendimentos obstétricos.
- A mortalidade caiu fortemente após a intervenção.
- Em séries temporais, esse caso pode ser visto como uma **intervenção** ou **quebra estrutural**.

Meteorologia: FitzRoy e a previsão do tempo

- Robert FitzRoy foi um dos pioneiros da previsão meteorológica moderna.
- Após o naufrágio do *Royal Charter*, em 1859, defendeu a criação de alertas de tempestades para proteger embarcações.
- Usava dados enviados por telégrafo: pressão atmosférica, vento, temperatura e condições do mar.
- A previsão surgia da comparação entre observações passadas e presentes.

dados no tempo → padrões atmosféricos → previsão

Economia: Jevons e os ciclos econômicos

- William Stanley Jevons observou que crises comerciais pareciam ocorrer em intervalos regulares.
- Tentou relacionar esses ciclos econômicos ao ciclo das manchas solares.
- A hipótese era que a atividade solar afetaria o clima, as colheitas, os preços e, por fim, a economia.
- Hoje, a explicação não é aceita como teoria geral, mas é um exemplo histórico de busca por padrões temporais.

manchas solares → clima → colheitas → preços e crises

Astronomia: Halley e a previsão de um cometa

- Edmond Halley analisou registros de cometas observados em 1531, 1607 e 1682.
- Percebeu que as observações poderiam corresponder ao mesmo cometa retornando periodicamente.
- Previu que o cometa retornaria por volta de 1758.
- O retorno confirmado mostrou a força de combinar dados históricos, regularidade temporal e modelo físico.

1531 $\longrightarrow$ 1607 $\longrightarrow$ 1682 $\longrightarrow$ 1758

observações passadas+padrão recorrente+modelo físico = previsão

Definição

DEF.: Uma **série temporal** é um conjunto de observações ordenadas segundo um índice que representa uma progressão temporal ou cronológica.

TIPOS: (i) **discretas** (tempo evolui de forma discreta) e (ii) **contínuas** (tempo evolui de forma contínua).

Exemplo de série temporal contínua:

$$y(t) = \alpha \sin(\beta t + \gamma), \quad t \in [0, \infty).$$

Nossa ênfase será em séries temporais discretas.

De início, assuma que cada observação y_t é uma **realização** de uma variável aleatória Y_t . Assim, uma **série temporal**

$$\{y_t, t \in \mathbb{T}\}$$

é uma **realização** de uma família de variáveis aleatórias

Definição

$\mathbb{T}$: conjunto índice, que ordenam as observações segundo a progressão cronológica do processo

Em geral,

$$\mathbb{T} = \{0, 1, 2, 3, \dots\} \quad \text{ou} \quad \mathbb{T} = \{1, 2, 3, \dots\}.$$

Notação alternativa:

$$Y(t, \omega),$$

onde t é o índice temporal e ω representa o elemento de aleatoriedade.

Tome:

- ▶ $Y(t, \omega)$
- ▶ $Y(t, \bar{\omega})$, com ω fixado
- ▶ $Y(\bar{t}, \omega)$, com t fixado
- ▶ $Y(\bar{t}, \bar{\omega})$, com t e ω fixados

IMPORTANTE: Para ω fixo, $Y(t, \bar{\omega})$ é uma função real de t , denominada **realização**, **trajetória** ou **caminho amostral**. Quando registrada ao longo do tempo, essa realização constitui uma **série temporal**, que pode ser de tempo discreto ou contínuo.

Série temporal e processo estocástico

Quando visualizamos o gráfico de valores de uma série ao longo do tempo (por exemplo, PIB, taxa de desemprego ou taxa de inflação), devemos lembrar que, conceitualmente, estamos visualizando o gráfico de

$$Y(t, \omega)$$

para ω fixo.

Série temporal: $Y(t, \omega)$, representando o **processo estocástico**, ou

$$Y(t, \bar{\omega}),$$

representando um **caminho amostral** ou uma **realização** do processo.

Confusão terminológica:

O termo **série temporal** é utilizado para denotar tanto um dado conjunto de observações ao longo do tempo, isto é, uma **realização**, quanto o seu processo gerador, isto é, o **processo estocástico**.

(Lembrando) Distribuição de uma variável aleatória

Para uma variável aleatória Y , sua função de distribuição é

$$F_Y(y) = P(Y \leq y).$$

Ela representa a probabilidade acumulada de Y assumir um valor menor ou igual a y .

1. Caso discreto

Se Y for discreta, definimos sua função de probabilidade por

$$p_Y(u) = P(Y = u).$$

Nesse caso, a função de distribuição é obtida por meio de uma soma:

$$F_Y(y) = \sum_{u \leq y} p_Y(u) = \sum_{u \leq y} P(Y = u).$$

Além disso,

$$P(a < Y \leq b) = \sum_{a < u \leq b} p_Y(u) = F_Y(b) - F_Y(a).$$

(Lembrando) Distribuição de uma variável aleatória

Se Y for contínua e possuir função densidade f_Y , então

$$F_Y(y) = \int_{-\infty}^y f_Y(u) du.$$

Além disso,

$$P(a < Y \leq b) = \int_a^b f_Y(u) du = F_Y(b) - F_Y(a).$$

Observação: No caso discreto, acumulamos probabilidades por **somas**; no caso contínuo, acumulamos probabilidades por **integrais**.

(Lembrando) Distribuição conjunta: caso contínuo

Considere o vetor aleatório contínuo

$$(Y_1, Y_2).$$

Sua **densidade conjunta** $f_{Y_1, Y_2}(y_1, y_2)$ descreve como a probabilidade está distribuída simultaneamente entre os possíveis valores de Y_1 e Y_2 .

Para ser uma densidade conjunta, deve satisfazer:

$$f_{Y_1, Y_2}(y_1, y_2) \geq 0$$

e

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{Y_1, Y_2}(y_1, y_2) dy_2 dy_1 = 1.$$

(Lembrando) Distribuição conjunta: caso contínuo

A função de distribuição conjunta acumulada é

$$F_{Y_1, Y_2}(a, b) = P(Y_1 \leq a, Y_2 \leq b),$$

e pode ser obtida por

$$F_{Y_1, Y_2}(a, b) = \int_{-\infty}^a \int_{-\infty}^b f_{Y_1, Y_2}(y_1, y_2) dy_2 dy_1.$$

A probabilidade de o vetor pertencer a uma região $A \subseteq \mathbb{R}^2$ é

$$P((Y_1, Y_2) \in A) = \iint_A f_{Y_1, Y_2}(y_1, y_2) dy_1 dy_2.$$

Em particular,


$$P(a < Y_1 \leq b, c < Y_2 \leq d) = \int_a^b \int_c^d f_{Y_1, Y_2}(y_1, y_2) dy_2 dy_1.$$

PS: A densidade conjunta descreve tanto o comportamento individual das variáveis quanto a possível **dependência** entre elas.


Distribuição conjunta: visualização

Distribuição conjunta contínua de duas variáveis aleatórias

Densidade conjunta



Função de distribuição conjunta acumulada



$$F_{Y_1, Y_2}(a, b) = P(Y_1 \leq a, Y_2 \leq b)$$



A distribuição conjunta descreve o comportamento simultâneo de Y_1 e Y_2 e sua **dependência**.

- ▶ À esquerda, temos a **densidade conjunta** $f_{Y_1, Y_2}(y_1, y_2)$;
- ▶ À direita, temos a **função de distribuição conjunta acumulada**.

(Lembrando) Distribuição de uma variável aleatória

3. Em um processo estocástico

Para o processo $\{Y_t : t \in \mathbb{T}\}$, selecionamos os índices $t_1, \dots, t_n$ e formamos o vetor aleatório

$$(Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}).$$


Sua função de distribuição conjunta é

$$F_{Y_{t_1}, \dots, Y_{t_n}}(y_1, \dots, y_n) = P(Y_{t_1} \leq y_1, \dots, Y_{t_n} \leq y_n).$$

No caso discreto, essa probabilidade pode ser obtida por somas múltiplas; no caso contínuo, por integrais múltiplas.

PS: A distribuição conjunta descreve o comportamento individual de cada variável e a **dependência entre diferentes índices do processo**.

Processo estocástico como uma família de distribuições




- Para cada instante t , Y_t é uma variável aleatória com uma distribuição de probabilidade.
- A curva $\mu(t)$ representa a evolução da média do processo ao longo do tempo.
- O conjunto $\{Y_t : t \in \mathbb{T}\}$ forma o processo estocástico.

O desafio

O grande desafio: Tipicamente, dispomos de apenas um caminho amostral para realizar inferências sobre o processo estocástico que o gerou.

Processo estocástico: visualização



Em essência...



Em essência, há dois grandes “tipos” de séries temporais: **bem comportadas** e **mal comportadas**.

Séries bem comportadas: produzem caminhos amostrais típicos, representativos.

Séries mal comportadas: produzem caminhos amostrais atípicos, não representativos.

Terminologia: Séries temporais **estacionárias** (bem comportadas) e **não estacionárias** (mal comportadas).

Exemplos de séries temporais



Estacionariedade estrita ou forte

Um processo estocástico $\{Y_t : t \in \mathbb{T}\}$ é **fortemente estacionário** quando sua distribuição probabilística não se altera ao deslocarmos o processo no tempo.

Formalmente, para quaisquer instantes $t_1, \dots, t_n$ e qualquer deslocamento h ,

$$(Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}) \stackrel{d}{=} (Y_{t_1+h}, Y_{t_2+h}, \dots, Y_{t_n+h}),$$

onde $\stackrel{d}{=}$ significa igualdade em distribuição.

Isso significa que

$$\begin{aligned} P(Y_{t_1} \leq y_1, \dots, Y_{t_n} \leq y_n) \\ = P(Y_{t_1+h} \leq y_1, \dots, Y_{t_n+h} \leq y_n). \end{aligned}$$

- ▶ Todas as distribuições conjuntas são preservadas.
- ▶ A posição absoluta no tempo não importa.
- ▶ Importa apenas a disposição relativa dos instantes.

PS: o calendário muda, mas as regras probabilísticas permanecem as mesmas.

Momentos de um processo estocástico

Para cada instante t , Y_t é uma variável aleatória. Alguns aspectos do processo podem ser descritos por seus **momentos de primeira e segunda ordem**.

Média ou momento de primeira ordem:

$$\mu_t = \mathbb{E}(Y_t),$$

que representa o nível médio do processo no instante t .

Momentos de um processo estocástico

Covariância ou estrutura de segunda ordem:

$$\gamma_{t,s} = \text{Cov}(Y_t, Y_s) = \mathbb{E}[(Y_t - \mu_t)(Y_s - \mu_s)] ,$$

que mede a associação linear entre os valores do processo nos instantes t e s .

Quando $t = s$, obtemos a variância:

$$\gamma_{t,t} = \text{Var}(Y_t) = \mathbb{E}[(Y_t - \mu_t)^2] .$$

PS: Para estudar a estrutura de segunda ordem, supomos que o processo tenha variância finita.

Adendo: momentos de ordens superiores fornecem outras características da distribuição. O terceiro momento central padronizado está associado à **assimetria**, enquanto o quarto momento central padronizado está associado à **curtose**.

Um processo $\{Y_t : t \in \mathbb{T}\}$ é **fracamente estacionário**, ou estacionário de segunda ordem, quando apresenta estabilidade na média e na covariância.

Condições:

- Média constante:

$$E(Y_t) = \mu, \quad \forall t.$$

- Variância finita e constante:

$$\text{Var}(Y_t) = \gamma(0) = \sigma^2, \quad \forall t.$$

- A covariância depende apenas da defasagem h , e não dos instantes específicos:

$$\text{Cov}(Y_t, Y_{t-h}) = \gamma(h).$$

PS: a série mantém o mesmo nível médio, a mesma variabilidade e a mesma estrutura de dependência temporal.

Estacionariedade forte e fraca

Estacionariedade forte	Estacionariedade fraca
Preserva todas as distribuições conjuntas.	Preserva apenas características de primeira e segunda ordem.
Analisa toda a estrutura probabilística.	Analisa média, variância e covariância.
É mais completa, mas difícil de verificar.	É mais simples e frequentemente utilizada na prática.

Quando os momentos de segunda ordem existem,

estacionariedade forte $\implies$ estacionariedade fraca.

Entretanto, em geral,

estacionariedade fraca $\nRightarrow$ estacionariedade forte.

Processos não estacionários


Um processo é **não estacionário** quando seu comportamento probabilístico muda ao longo do tempo.

Isso pode ocorrer por mudanças:


- ▶ na média ou no nível da série;
- ▶ na variância;
- ▶ na estrutura de dependência temporal;
- ▶ após uma quebra estrutural.

Exemplos de não estacionariedade


Na média




Na variância



Na dependência temporal



Quebra estrutural



Como diagnosticar a estacionariedade?

Principais ferramentas de diagnóstico:

- ▶ Inspeção gráfica da série;
- ▶ comparação da média e da variância em diferentes trechos;
- ▶ análise da função de autocorrelação;
- ▶ aplicação de testes estatísticos de estacionariedade ou de raiz unitária.

PS: nenhum desses instrumentos deve ser analisado isoladamente.

gráfico + ACF + testes formais $\longrightarrow$ diagnóstico

Exemplo: Dados do Ibovespa

Os dados históricos do Ibovespa podem ser obtidos diretamente no Python por meio do pacote `yfinance`.

Código em Python

```
import yfinance as yf

dados = yf.download(
    "^BVSP",
    start="2010-01-01",
    end="2025-12-31",
    auto_adjust=True,
    progress=False
)
```

- ▶ `^BVSP`: código do Ibovespa no Yahoo Finance.
- ▶ `start` e `end`: período da análise.
- ▶ `auto_adjust=True`: utiliza os preços ajustados.
- ▶ O objeto `dados` contém abertura, máxima, mínima, fechamento e volume.

Teste Augmented Dickey–Fuller (ADF)

O teste ADF é utilizado para investigar a presença de **raiz unitária** em uma série temporal.

Hipóteses do teste:

H_0 : a série possui raiz unitária;
a série é não estacionária.

H_1 : a série não possui raiz unitária;
a série é estacionária.

Regra de decisão:

- ▶ Se o p -valor for menor que o nível de significância, rejeitamos H_0 .
- ▶ Se o p -valor for maior ou igual ao nível de significância, não rejeitamos H_0 .

Para um nível de significância de 5%:

$$\begin{cases} p\text{-valor} < 0,05 & \Rightarrow \text{rejeitar } H_0; \\ p\text{-valor} \geq 0,05 & \Rightarrow \text{não rejeitar } H_0. \end{cases}$$

Aplicação do teste ADF

Aplicamos o teste Augmented Dickey–Fuller sobre os valores de fechamento do Ibovespa.

Código em Python

```
from statsmodels.tsa.stattools import adfuller

# Selecionando o fechamento do Ibovespa
serie = dados["Close"].dropna()

# Aplicando o teste ADF
resultado = adfuller(serie)

# Resultados
print("Estatística ADF:", resultado[0])
print("p-valor:", resultado[1])
```

- ▶ `resultado[0]`: estatística do teste ADF.
- ▶ `resultado[1]`: p -valor do teste.

Diferenciação

Uma das formas mais comuns de tratar uma série não estacionária é calcular suas diferenças.

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1}.$$

Em vez de analisarmos o nível da série, passamos a analisar a mudança ocorrida entre dois períodos consecutivos.

Por exemplo, se uma série apresenta os valores

$$100, \quad 103, \quad 101, \quad 106,$$

sua primeira diferença será

$$3, \quad -2, \quad 5.$$

Interpretação: a diferenciação remove parte da persistência presente no nível da série e pode torná-la mais estável ao longo do tempo.

Atividade:

- ▶ Calcule a primeira diferença da série de fechamento do Ibovespa:

$$\Delta Y_t = Y_t - Y_{t-1}.$$

- ▶ Em seguida, aplique novamente o teste Augmented Dickey–Fuller na série diferenciada.
- ▶ Compare o novo p -valor com o obtido para a série original.

Atividade:

- ▶ Calcule a primeira diferença da série de fechamento do Ibovespa:

$$\Delta Y_t = Y_t - Y_{t-1}.$$

- ▶ Em seguida, aplique novamente o teste Augmented Dickey–Fuller na série diferenciada.
- ▶ Compare o novo p -valor com o obtido para a série original.

Código em Python

```
# Primeira diferença
serie_diferenciada = serie.diff().dropna()

# Novo teste ADF
resultado_diff = adfuller(serie_diferenciada)

print("Estatística ADF:", resultado_diff[0])
print("p-valor:", resultado_diff[1])
```

A diferenciação funciona sempre?

A diferenciação funciona sempre?

Não.

A **não estacionariedade** não é oriunda de uma única causa. Diferentes séries podem ser não estacionárias por motivos distintos.

- ▶ A média pode mudar ao longo do tempo;
- ▶ a variância pode aumentar ou diminuir;
- ▶ a dependência temporal pode se modificar;
- ▶ pode ocorrer uma quebra estrutural;
- ▶ os choques podem se acumular permanentemente.

PS: diferenciar sem identificar a causa pode não resolver o problema e ainda alterar desnecessariamente a dinâmica da série.

o tratamento deve depender da causa da não estacionariedade

Causas da não estacionariedade

Causa	O que muda ao longo do tempo
Tendência determinística	O nível médio da série cresce ou diminui de forma sistemática.
Raiz unitária	Os choques se acumulam e alteram permanentemente o nível da série.
Sazonalidade	A média muda de maneira periódica e previsível.
Variância não constante	A amplitude das oscilações aumenta ou diminui.
Quebra estrutural	O nível ou os parâmetros mudam abruptamente em determinado instante.
Dependência temporal variável	A relação entre o presente e o passado se modifica.

PS: séries com aparência visual semelhante podem possuir mecanismos geradores completamente diferentes.

Tratamentos para a não estacionariedade

Problema identificado	Tratamento possível
Tendência determinística	Estimar e remover a tendência.
Raiz unitária	Aplicar diferença regular: $\Delta Y_t = Y_t - Y_{t-1}$.
Sazonalidade	Ajuste sazonal ou diferença sazonal: $\Delta_s Y_t = Y_t - Y_{t-s}$.
Variância não constante	Transformações como logaritmo ou Box-Cox.
Quebra estrutural	Variáveis indicadoras, intervenção ou modelos por regimes.
Dependência temporal variável	Modelos com parâmetros variáveis ao longo do tempo.

diagnosticar $\longrightarrow$ identificar a causa $\longrightarrow$ escolher o tratamento

PS: após qualquer transformação, devemos verificar novamente se o comportamento da série se tornou aproximadamente estacionário.

Exemplo: AirPassengers

A série **AirPassengers** contém o número mensal de passageiros internacionais entre 1949 e 1960.

Código em Python

```
import statsmodels.api as sm

dado = sm.datasets.get_rdataset(
    "AirPassengers",
    package="datasets"
).data
```

- ▶ **time**: período da observação;
- ▶ **value**: número de passageiros, em milhares.

Exemplo: série Lake Huron

O conjunto de dados **LakeHuron** contém medições anuais do **nível do Lago Huron**, um dos Grandes Lagos da América do Norte.

- ▶ Período: **1875 a 1972**;
- ▶ Frequência: **anual**;
- ▶ Total: **98 observações**.

Código em Python

```
import statsmodels.api as sm

dado = sm.datasets.get_rdataset(
    "LakeHuron",
    package="datasets"
).data

print(dado.head())
```

O teste **KPSS** (Kwiatkowski–Phillips–Schmidt–Shin) investiga se uma série pode ser considerada estacionária em torno de uma constante ou de uma tendência determinística.

Hipóteses do teste:

H_0 : a série é estacionária

H_1 : a série é não estacionária.

A hipótese nula depende da especificação utilizada:

► **KPSS em nível:**

H_0 : Y_t é estacionária em torno de uma média constante.

► **KPSS com tendência:**

H_0 : Y_t é estacionária em torno de uma tendência determinística.

Regra de decisão:

estatística KPSS grande $\implies$ rejeitar H_0 .

Portanto, o teste é de **cauda direita**.

$p\text{-valor} < \alpha \implies$ rejeitar a estacionariedade.

Exemplo: European Stock Markets

O conjunto de dados **EuStockMarkets** contém os valores de fechamento de quatro importantes índices do mercado acionário europeu.

- ▶ Período: **1991 a 1998**;
- ▶ Frequência: **diária**;
- ▶ Total: **1.860** observações;
- ▶ Índices: **DAX, SMI, CAC e FTSE**.

Neste exemplo, utilizaremos o **DAX**, índice do mercado acionário alemão, expresso em **pontos de índice**.

Código em Python

```
import statsmodels.api as sm

dado = sm.datasets.get_rdataset(
    "EuStockMarkets",
    package="datasets"
).data

y = dado["DAX"]
```

Synced